

Proyecto 1: LSA con SVD

Análisis semántico latente de tramas de películas

Curso: IMT2230 — Álgebra Lineal Avanzada y Modelamiento

Profesor: Felipe Urrutia

Ayudante: Luis Castillo

Integrantes: Alonso Aqueveque, Alex Nieves, Francisco Reyes

Fecha: mayo 2026

Introducción

Para este proyecto el corpus a utilizar corresponde a descripciones de la tramas de películas, estas son extraídas de Wikipedia y recopiladas en formato CSV, disponible públicamente en Kaggle bajo el nombre de Wikipedia Movie Plots. El dataset completo contiene 34886 películas publicadas entre 1901 y 2017.

Para este análisis en particular se seleccionaron 500 documentos aleatorios, ya que utilizar el dataset completo es un proceso muy exigente para nuestros computadores, además acotaremos los géneros a 5 (drama, comedia, horror, acción y romance) y usaremos 100 películas por cada uno.

El principal motivante de este corpus para el proyecto es que consideramos que cada género se asociaría a vocabularios distintos entre sí, lo que nos hace creer que permite ver con claridad si el proceso SVD logra separar los documentos por temática y así diferenciar entre géneros. Cabe mencionar que los textos que explican las tramas de las películas son textos lo suficientemente largos como para que el análisis tenga sentido.

Hipótesis

Esperamos que con las primeras componentes obtenidas de SVD se capturen diferencias temáticas entre los géneros cinematográficos, nosotros creemos que esto se puede reflejar de dos maneras, y que no son necesariamente excluyentes entre sí, así que las anunciaremos:

La primera forma que anticipamos que se puedan diferenciar los géneros es a través de la distribución de las películas en el espacio vectorial, en específico pensamos que estas se agruparon en regiones distintas según su género.

Otra posible forma en la que podría reflejar la diferenciación de los géneros es con los primeros 5 componentes de la matriz, así esperaríamos que cada vector pudiera representar de alguna manera cada uno de los géneros.

Preprocesamiento:

Antes de construir la matriz usada en el proceso SVD, limpiamos y preparamos el formato de la información de los textos con las siguientes decisiones:

1. Normalización del texto: eliminamos referencias entre corchetes, caracteres especiales y espacios extra que venían en los textos originales de Wikipedia
2. Lematización con spaCy: reducimos cada palabra a su forma base, así *killed*, *killing* y *killer* no se tratan como palabras distintas
3. Stopwords: removimos las stopwords estándar de spaCy más palabras genéricas del dominio como *film*, *movie*, *scene* y *story*, que aparecen en casi todas las películas y no dicen nada útil sobre el género
4. Nombres propios: Para que los nombres de personas no contaminen el vocabulario se pueden identificar gracias a los token (Punto 2, Celda 1), estos reconocen nombres propios usando "PROPN" o nombres de personas "PERSON". Decidimos usar "PROPN" por sobre "PERSON" ya que "PERSON" tiene dificultades para reconocer nombres de otras culturas y esto puede interferir en el proceso, esta decisión también tiene sus contras ya que la presencia en los textos de lugares específicos, como París o medio oriente, podría ayudar a separar entre géneros cinematográficos, pero consideramos que esta medida es la que interfiere menos.
5. TF-IDF con bigramas: usamos "Tfidf Vectorizer" (Punto 3, Celda 1) con "ngram_range=(1,2)" (Punto 3, celda 1) para capturar frases como "*serial killer*" o "*happy ending*", "min_df=3" (Punto 3, celda 1) y así descartar términos que aparecen en muy pocas películas, y "max_df=0.85" (Punto 3, celda 1) para ignorar los que aparecen en casi todas

Como resultado de aplicar todo este preprocesamiento, el vocabulario se va reduciendo en cada paso: empezamos con **27.566 términos únicos** en el texto crudo, bajamos a **8.407 términos** después de la lematización y filtrado con spaCy, y terminamos con un vocabulario de **4.494 términos** después de aplicar TF-IDF con min_df y max_df. Este último valor es el tamaño que usaremos para construir nuestra matriz textual.

Metodología

Empezamos a realizar la construcción de la matriz textual, la cual será analizada con SVD. Las decisiones técnicas tomadas y las características de la matriz resultante son las siguientes:

La matriz textual fue creada con TF-IDF y optamos por trabajar con una matriz término-documento. Dado que los vectorizadores de la librería scikit-learn entregan por defecto una estructura de documento-palabra, aplicamos una operación de transposición al resultado del vectorizador como es sugerido en la rúbrica. Así las filas de nuestra matriz representan los términos únicos del vocabulario y las columnas representan los documentos individuales del corpus.

La matriz final A tiene una dimensión de 4494 filas o términos por 500 columnas o documentos.

En la matriz A cada valor de A_{ij} indica la importancia que la palabra en la posición i tiene para el texto en la posición j, esta importancia es asignada por el procesamiento TF-IDF. En la investigación nos ayudará a reconocer los términos relevantes de las sinopsis de cada película (filas y columnas).

Consideramos que estas decisiones son suficientes para que la matriz refleje las diferencias reales entre géneros. El objetivo es eliminar el "ruido" suficiente para que el análisis encuentre patrones en los datos.

Aplicación de SVD:

La descomposición de nuestra matriz A , nos entregó elementos como valores singulares, vectores singulares izquierdos y derechos. Que nos dicen que, cuantos y de qué hablan los temas:

Valores singulares: matemáticamente hablando, son los números en la diagonal de la matriz ordenados de mayor a menor. Representando la importancia o la influencia de cada concepto latente descubierto en el corpus. En nuestro contexto lo interpretamos como la representación de temáticas o campos semánticos presentes en las películas presentes en el corpus. Volviendo a lo matemático un valor singular grande indica que ese componente captura una gran parte de la estructura de los datos.

Vectores singulares izquierdos: matemáticamente son las columnas de la matriz ortogonal que relacionan las palabras con los valores singulares. Con esto en mente significa que la relación entre las palabras con los campos semánticos o las temáticas presentes.

Vectores singulares derechos: Matemáticamente son las filas de la matriz que relacionan los documentos con los temas latentes. O sea que este vector nos muestra cómo cada documento se distribuye o se proyecta sobre los conceptos latentes descubiertos en las componentes singulares. Otra forma de verlo es ver el valor que te indica "cuánto de este tema" hay en un documento específico. Un documento sobre cosas de terror tendrá un valor muy alto en la componente que pudiera relacionarse a lo sobrenatural o a crímenes, pero casi nulo en una componente que agrupa palabras de "Amor".

Dimensión elegida:

Para poder definir la cantidad de valores singulares a utilizar se decidió graficar los valores singulares con el fin de determinar cuales de estos dejan de tener relevancia al momento de definir la trama de una película, y también para evitar overfitting.

También se intentó usar alguna medida estadística que nos ayude a definir un buen rango para el valor de k , con este objetivo usamos una definición de varianza sugerida por la IA, al final no la tomamos en gran consideración pero pensamos que puede ser interesante su presencia en el notebook.

Para poder generar el gráfico de Decaimiento de valores singulares se decidió limitar la cantidad de valores singulares de la matriz A a 50. En el gráfico se observa una depresión pronunciada en los primeros 4-5 valores singulares, seguido de un descenso lento. Junto con lo visto por el gráfico y considerando la clasificación de las películas a 5 géneros decidimos definir la exploración de las 5 componentes singulares más importantes.

Visualización de documentos y palabras según componentes:

Una vez que tenemos calculada la descomposición SVD, podemos usar las componentes que elegimos para representar tanto los documentos como los términos en un espacio de pocas dimensiones. Esto nos permite visualizar de manera concreta las relaciones que hasta ahora solo veíamos como números. Para esto el enunciado nos sugiere la construcción de coordenadas.

Para implementarlas en código definimos dos funciones (Punto 7, Celda 1): `coordenadas_documentos` recibe `sigma`, `Vt` y el par de componentes elegido, y devuelve una matriz $2 \times n$ con las coordenadas de los documentos en sus columnas; `coordenadas_terminos` recibe `U`, `sigma` y el par de componentes, y devuelve una matriz $m \times 2$ con las coordenadas de los términos en sus filas. Estas dos funciones son usadas por `graficar_lsa`, que para cada par de componentes muestra dos paneles: el izquierdo con los 500 documentos coloreados por género, y el derecho con los 40 términos de mayor norma, coloreados por su peso TF-IDF acumulado.

En el notebook 'Exploración gráficos' tenemos todos los gráficos que pudimos imaginar que entregarían información relevante sobre el corpus.

Al momento de visualizar los documentos y las palabras según las componentes notamos que existen dos tipos de gráficos, los que tienen al componente 1 y los que no lo tienen, de esta manera decidimos que con la presentación de 2 gráficos basta para comprender el comportamiento de los documentos y las palabras:

Gráficos componentes 1 vs 2: Cuando se tiene la componente 1 notamos que la distribución de los documentos no es de agrupaciones por género como nosotros pensábamos, se notan tendencias en cada género pero estos no están claramente separados en grupos, sino que el comportamiento es un desplazamiento de todos los géneros hacia el mismo sentido, este comportamiento también es presente en la distribución de las palabras en su respectiva gráfica. Este fenómeno lo interpretamos como que el vocabulario de las sinópsis de películas tiene sus propias características que hace que se repitan los mismos temas en todas, así el apelar al amor ('love') y a la violencia ('kill') son temáticas que se comparten en las películas.

Gráficos componentes 3 vs 4: Este es representativo del comportamiento cuando no se usa la componente 1, para los documentos podemos notar cómo estos se mueven alrededor del origen y, aunque las separaciones en grupos no son marcadas, podemos notar las tendencias de los géneros de estar localizadas en uno de los sentidos de cada eje, un ejemplo sería notar que las películas de horror están principalmente posicionadas en los valores positivos de la componente 4 mientras que las películas de acción están posicionadas en los valores negativos. En la distribución de las palabras notamos que estas rodean el origen pero ninguna se encuentra directamente en este.

Exploración semántica:

En esta parte exploramos tres tipos de relaciones que consideramos representan el espacio reducido: entre componentes y palabras, entre géneros y componentes, y entre géneros y palabras.

Componentes y palabras: En (Punto 8, Celda 1) listamos las 14 palabras con mayor valor absoluto en cada componente, separadas entre positivas y negativas. Esto nos permite asignarle un significado temático aproximado a cada eje, ya que las componentes no traen una etiqueta clara y hay que deducir mirando qué palabras cargan en cada lado. Por ejemplo, en la componente 2 aparecen palabras como ‘kill’, ‘attack’, ‘zombie’ y ‘vampire’ en el lado positivo, y ‘love’, ‘marry’, ‘fall love’ y ‘family’ en el negativo, lo que nos hace pensar que esta componente opone vocabulario de horror y acción a vocabulario romántico y familiar.

Géneros y componentes: En (Punto 8, Celda 2) generamos un heatmap con la coordenada media de cada género en cada componente, lo que nos permite ver de un vistazo cómo se posiciona cada género en cada eje. Acá nos dimos cuenta de algo importante: las componentes no representan a un género en específico, sino que más bien sirven para diferenciar entre géneros, en particular de la componente 2 a la 5, ya que como notamos antes la componente 1 desplaza a todo el corpus en la misma dirección. Tomando como ejemplo la componente 2, vemos que horror y action quedan en el lado positivo mientras que romance queda en el negativo, osea que esta componente no es la "componente de horror" ni la "componente de romance" por separado, sino un eje que separa dos grupos de géneros con vocabulario distinto. Las componentes 3, 4 y 5 siguen el mismo patrón, cada una separando otros pares de géneros según el vocabulario que tienen en común.

Géneros y palabras: En (Punto 8, Celdas 3 y 4) visualizamos los términos más frecuentes del corpus, tanto a nivel global como separados por género. Esta vista no pasa por el espacio reducido, así que nos sirve como verificación cualitativa: las palabras que dominan cada género coinciden con las que cargan en las componentes principales, lo que refuerza la interpretación que hicimos de cada eje.

Conclusiones y Discusión:

Al comparar los resultados con nuestra hipótesis inicial, encontramos que efectivamente se logran captar diferencias temáticas entre los géneros cinematográficos, así que en lo general la hipótesis se cumple. Sin embargo, la forma en la que aparece esta diferenciación no es exactamente la que habíamos previsto: anticipamos que cada componente iba a representar de alguna manera a un género específico, pero lo que observamos es más bien que las componentes funcionan como ejes que separan pares de géneros con vocabulario distinto, especialmente de la componente 2 a la 5. Osea que la diferenciación entre géneros existe, pero se da a través de la comparación entre temáticas y no de una asociación directa entre una componente y un género.

Sobre las limitaciones del análisis, hay un par de cosas que vale la pena mencionar. Primero, trabajamos con una muestra de 500 películas tomadas de un dataset que contiene casi 35.000, así que un análisis usando el corpus completo podría mostrar separaciones más claras entre géneros, además de capturar subgéneros y matices que con 100 películas por categoría no alcanzamos a ver. Segundo, en el preprocesamiento decidimos eliminar todos los tokens marcados como PROP, lo que también

descarto nombres de lugares como ciudades o regiones; una mejora interesante sería refinar este filtrado para mantener los nombres de lugares pero descartar los nombres de personas, ya que los lugares pueden aportar información útil para diferenciar géneros (por ejemplo, 'Paris' en una película romántica versus un escenario rural en una de acción).

Conclusión final:

LSA con SVD nos permitió descubrir estructura temática latente en el corpus de tramas de películas, lo que valida nuestra hipótesis inicial de que las primeras componentes capturan diferencias entre géneros. Lo más interesante es que esta captura ocurre de una manera distinta a la que anticipamos: las componentes no se asocian a un género en particular, sino que funcionan como ejes que separan pares de géneros con vocabulario contrastante. Al fin y al cabo, LSA termina siendo una herramienta exploratoria útil para visualizar y entender la estructura temática de un corpus, pero no funciona como un clasificador directo de géneros.

Datos y reproducibilidad

Link GitHub:

<https://github.com/Prodigy0101/Proyecto-de-Algebra-Lineal-Avanzada-y-Modelamiento.git>

El corpus utilizado es el dataset **Wikipedia Movie Plots** disponible públicamente en Kaggle. Se descarga desde el siguiente enlace:

<https://www.kaggle.com/datasets/jrobischon/wikipedia-movie-plots>

El archivo descargado (wiki_movie_plots_deduped.csv) debe ubicarse en el mismo directorio del notebook Desarrollo.ipynb para que el código corra sin modificaciones.